FRAUD TEAM

ÍNDICE

1. **Descripción del proyecto**
2. **Carga de datos**

   2.1 Histogramas de los datos

3. **Limpieza de datos**

   3.1 Eliminación de columnas repetidas y duplicadas

   3.2 Missing data

   3.3 Conversión de valores categóricos

   3.4 Eliminación de missing values

   3.5 Imputación

   3.6 Matriz de correlación

   3.7 RFE y PCA y SVD

ÍNDICE

4. **Selección de variables**

4.1 Categóricas

4.1.1 Estadístico chi 2

4.1.2 Estadístico de información mutua

4.2 Numéricas

4.2.1 Coeficiente de correlación ANOVA

4.2.2 Estadístico de información mutua

5. **Importancia de variables**

6. **Modelos**

7. **Deep Learning**

8. **Conclusiones**

Descripción del proyecto

1. Descripción del proyecto

CREACIÓN DE UN MODELO DE ***MACHINE LEARNING***

PREDECIR LAS RECLAMACIONES FRAUDULENTAS DE UN SEGURO DE VEHÍCULOS

Carga de datos

2. Carga de datos

Leemos los datos del fichero CSV donde están todos los datos y los mostramos en un dataset, obteniendo como resultado:

```
dataset =
pd.read_csv('insurance_claims.cs
v',na_values='?')
```

	months_as_customer	age	policy_number	policy_bind_date	policy_state	policy_csl	policy_deductable	policy_annual_premium	umbrella_limit	insured_zip	insured_sex	insured_education_level
0	328	48	521585	2014-10-17	OH	250/500	1000	1406.91	0	466132	MALE	MD
1	228	42	342868	2006-06-27	IN	250/500	2000	1197.22	5000000	468176	MALE	MD
2	134	29	687698	2000-09-06	OH	100/300	2000	1413.14	5000000	430632	FEMALE	PhD
3	256	41	227811	1990-05-25	IL	250/500	2000	1415.74	6000000	608117	FEMALE	PhD
4	228	44	367455	2014-06-06	IL	500/1000	1000	1583.91	6000000	610706	MALE	Associate
...	...	...	...	...	...	...	...	...	...	...	...	...
995	3	38	941851	1991-07-16	OH	500/1000	1000	1310.80	0	431289	FEMALE	Masters
996	285	41	186934	2014-01-05	IL	100/300	1000	1436.79	0	608177	FEMALE	PhD
997	130	34	918516	2003-02-17	OH	250/500	500	1383.49	3000000	442797	FEMALE	Masters
998	458	62	533940	2011-11-18	IL	500/1000	2000	1356.92	5000000	441714	MALE	Associate
999	456	60	556080	1996-11-11	OH	250/500	1000	766.19	0	612260	FEMALE	Associate

1000 rows × 40 columns

2.1 Histograma de los datos

Se representan gráficamente todas las variables en forma de barras. Se obtiene una vista general de la distribución de los datos.
De esta manera, vemos la tendencia de los datos por ubicarse hacia una determinada región de valores dentro del espectro de valores posibles y podemos observar el grado de homogeneidad o disparidad de los datos.

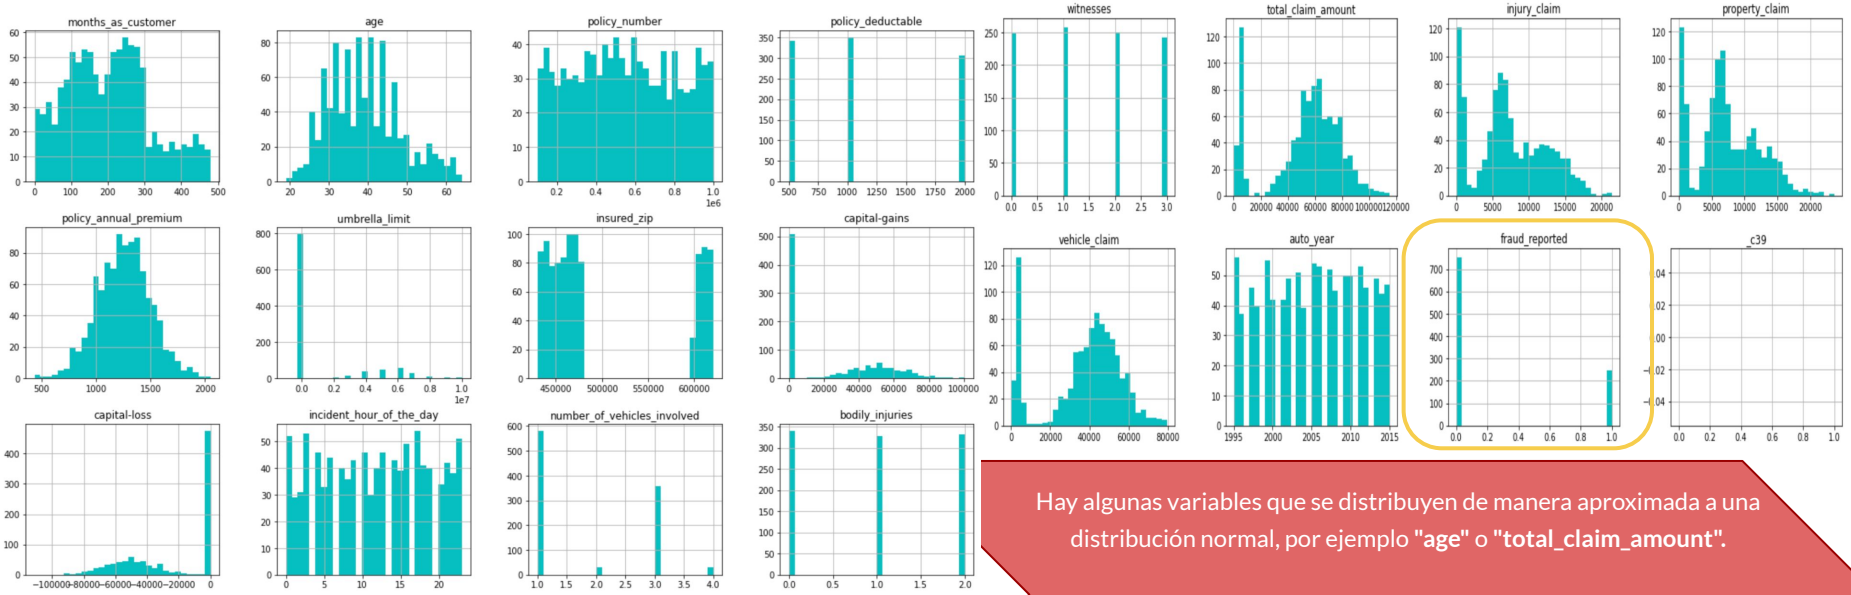

Hay algunas variables que se distribuyen de manera aproximada a una distribución normal, por ejemplo **"age"** o **"total_claim_amount".**

Nuestro conjunto de datos, <u>es un conjunto desbalanceado</u> ya que nuestra variable a predecir, "fraud_reported", tiene muchos más casos donde "frad_reported" es no (0), respecto a los casos donde sí hay fraude (1).

Limpieza de datos

3. Limpieza de datos

Filtrado de columnas

Se elimina aquella columna:

- Repetida o duplicada.
- Superflua, que no aporta información (como las que tienen un valor diferente para cada registro).

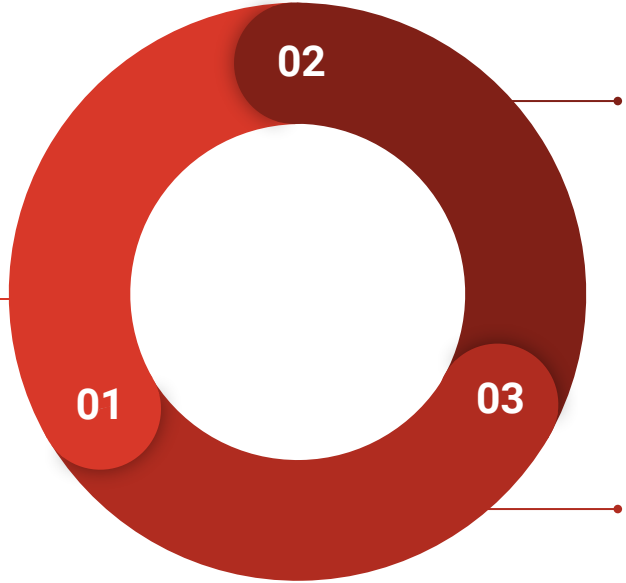

Estudio de los NaN

Se analizan los missing data para determinar si existe algún patrón en la aparición de estos valores en el dataset.

Se tienen unos 200-400 missing values en tan solo tres variables. Se determina que estos valores no aportan información.

Conversión de los valores categóricos

Se convierten los valores categóricos a numéricos para poder realizar las siguientes técnicas mediante la función ***OrdinalEncoder***.

3.1 Eliminación de columnas repetidas y duplicadas

```
policy_number                  1000
incident_location              1000
insured_zip                     995
policy_annual_premium           991
policy_bind_date                951
total_claim_amount              763
vehicle_claim                   726
injury_claim                    638
property_claim                  626
months_as_customer              391
capital-loss                    354
capital-gains                   338
incident_date                    60
age                              46
auto_model                       39
incident_hour_of_the_day         24
auto_year                        21
insured_hobbies                  20
insured_occupation               14
auto_make                        14
umbrella_limit                   11
incident_state                    7
incident_city                     7
insured_education_level           7
insured_relationship              6
authorities_contacted             5
collision_type                    4
incident_type                     4
incident_severity                 4
number_of_vehicles_involved       4
witnesses                         4
property_damage                   3
policy_deductable                 3
policy_csl                        3
policy_state                      3
bodily_injuries                   3
police_report_available           3
insured_sex                       2
fraud_reported                    2
dtype: int64
```

Variables que aportan un dato diferente para cada registro:

- **policy_number**
- **insured_zip**
- **policy_bind_date**
- **incident_location**.

- **incident_date**: solo cuenta con fechas correspondientes a enero y febrero y por lo tanto, al no estar distribuida por todos los meses, tampoco aporta información.

3.2 Missing data

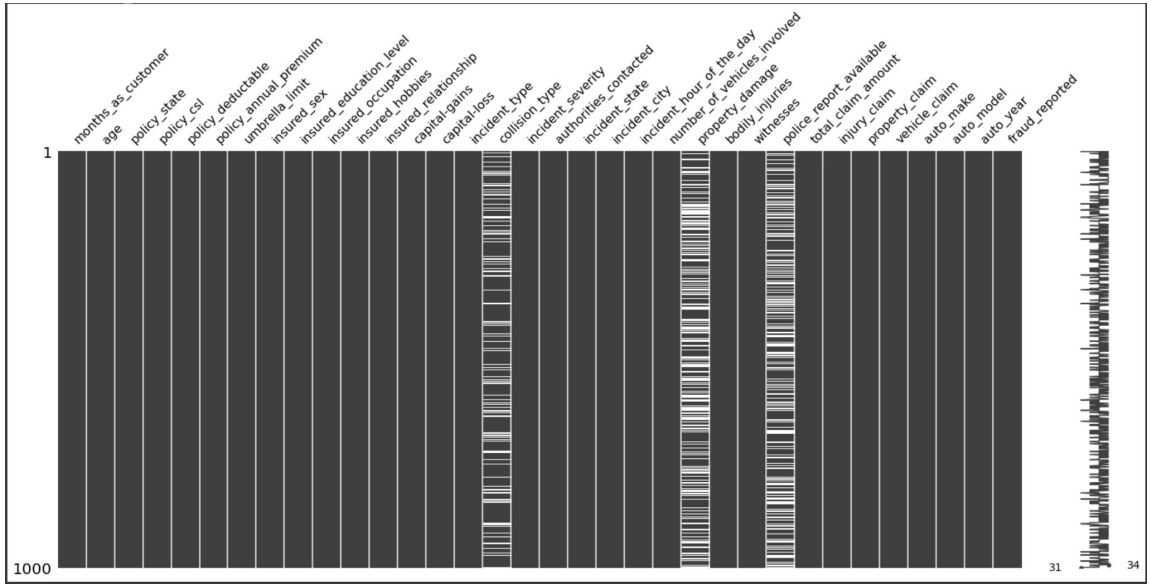

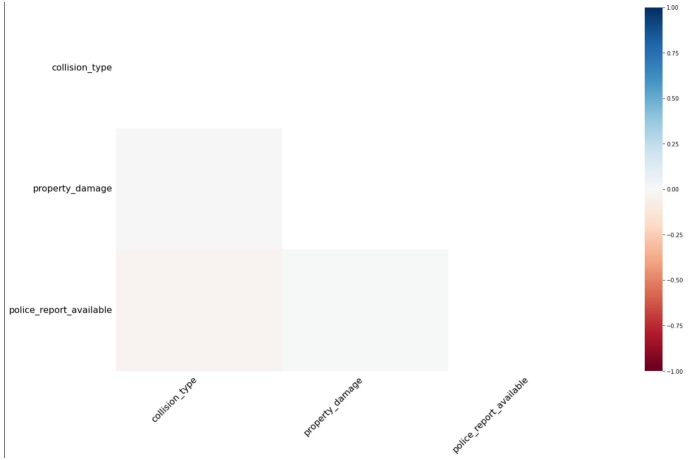

Se realizó un gráfico de barras con el número de missing values de cada variable

Se determinó que los missing values de estas variables no están correlados.

3. Limpieza de datos

Eliminación de los missing values

Se determina que borrar los missing values comporta una pérdida de información muy importante ya que se eliminan muchas columnas.

Así pues, no se eliminarán, sinó que se ***imputarán***.

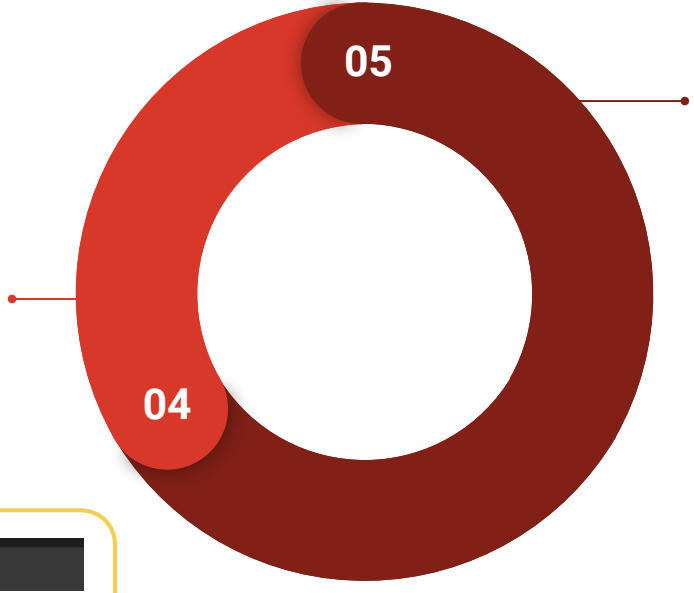


```
Dimension con nan: (1000, 34)
```

```
Dimension sin nan: (340, 34)
```

Imputación

Se estudian distintos métodos de imputación:

- **ESTADÍSTICA**: Se reemplazan los NaN según la estadística calculada (media, mediana, frecuencia o constante)
- **KNN:** Se imputa según el promedio el valor de los K vecinos más cercanos
- **ITERATIVA**: Se imputa secuencialmente usando los valores anteriores para predecir los siguientes.

El método con el que se obtienen unos resultados más precisos es:

KNN con 3 vecinos

3. Limpieza de datos

Matriz de correlación

Despliega un gráfico con valores del 0 al 1 que muestran la relación entre las variables, siendo el 1 el mayor grado de relación.

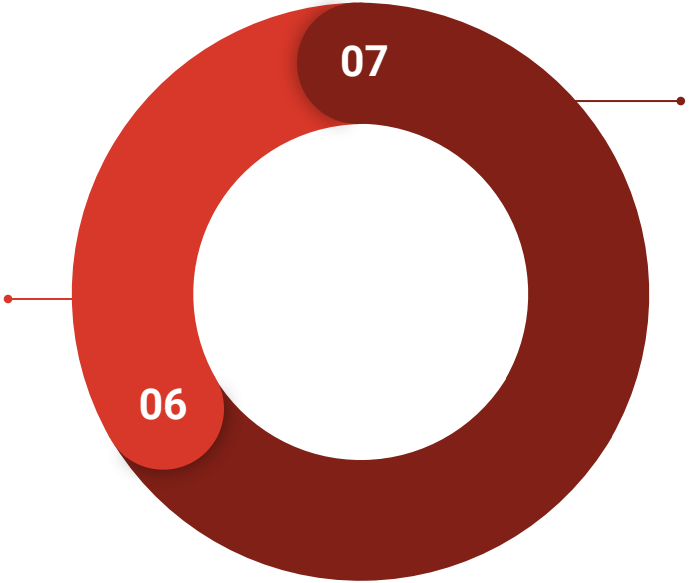

RFE y PCA y SVD

- RFE: Ordena las variables de acuerdo a una medida de la importancia de cada variable dada por un clasificador.
- PCA y SVD: se utilizan para eliminar datos redundantes, es decir, para reducir la dimensionalidad.

3.7 Matriz de correlación

Hay parejas de columnas que están altamente relacionadas:

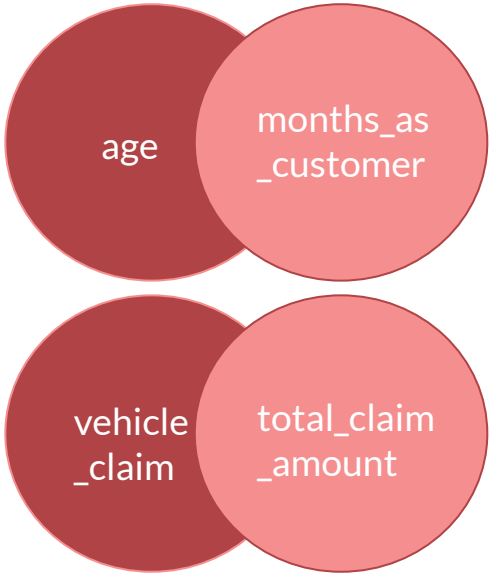

Nos quedaremos con aquella columna más correlacionada con Fraud_reported.

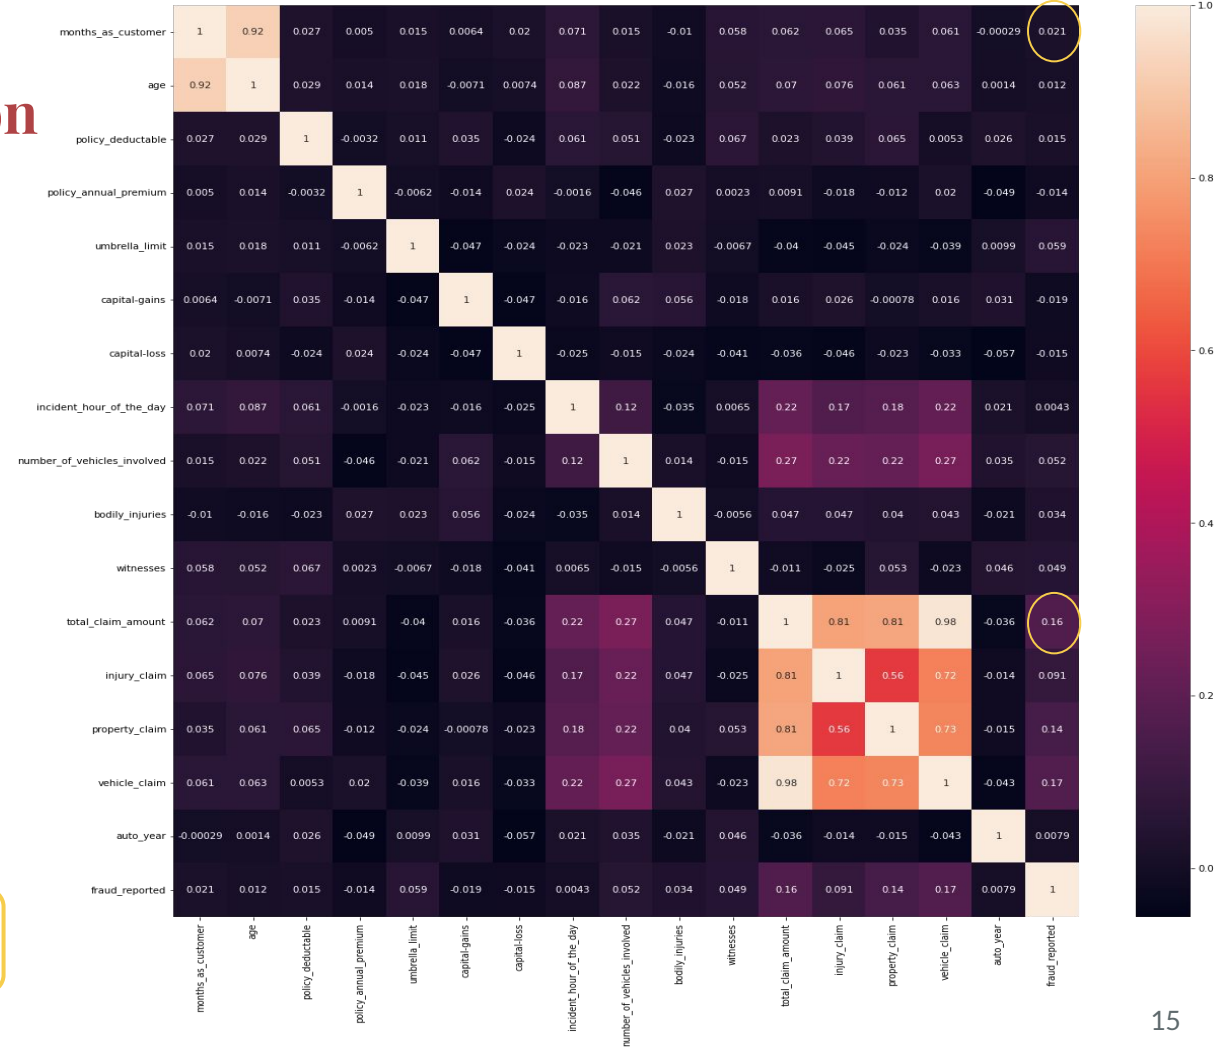

Selección de variables

4.1 Categóricas

4. Selección de variables

- **Variable numérica de entrada / categórica de salida**: Este es un problema de modelado predictivo de clasificación con variables de entrada numéricas. Esto podría ser el ejemplo más común de un problema de clasificación. Las técnicas más comunes se basan en la correlación, aunque en este caso deben tener en cuenta la variable objetivo.
  - Coeficiente de correlación ANOVA (lineal).
  - Coeficiente de rango de Kendall (no lineal). Kendall asume que la variable categórica es ordinal.
  - Información mutua.

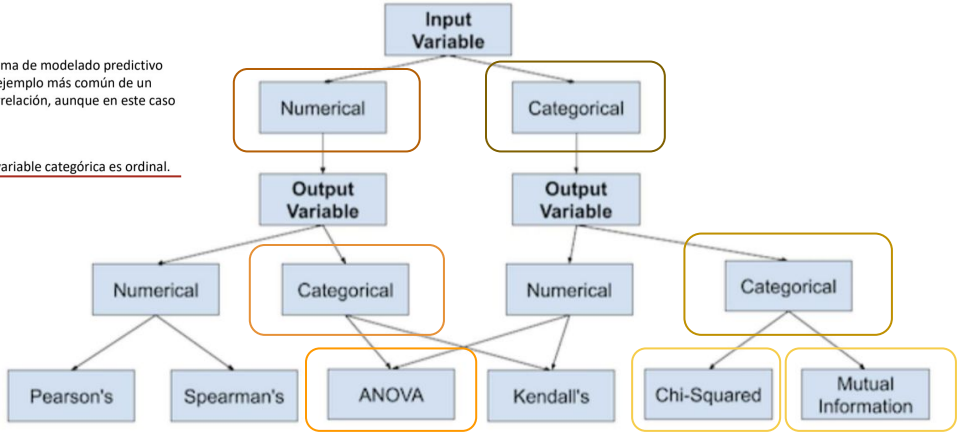

Selección de los métodos que utilizaremos para llevar a cabo la selección de variables:

Variables de entrada: CATEGÓRICAS y NUMÉRICAS

Salida: CATEGÓRICA

4.1 Categóricas

4.1.1 CHI-2

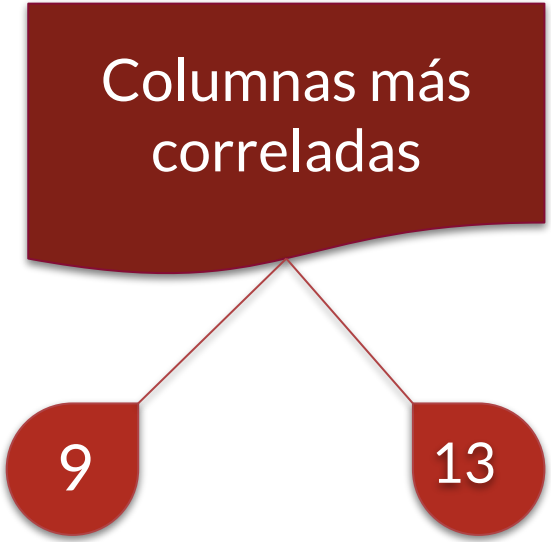

CHI-2

Devuelve el grado de dependencia entre las variables y la variable etiqueta

4.1 Categóricas

4.1.1 Información mutua

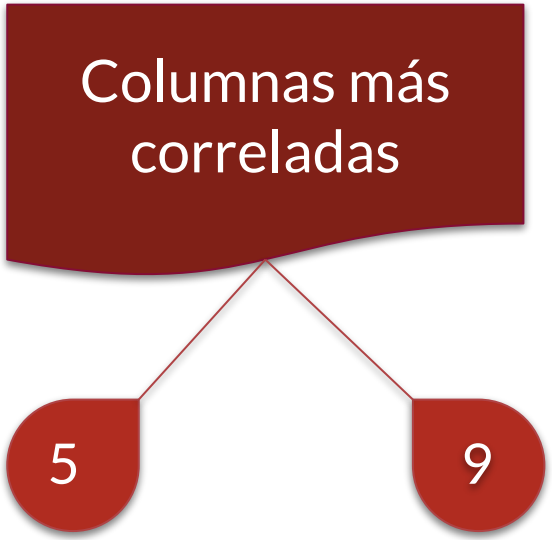

INFORMACIÓN MUTUA

Devuelve el grado de dependencia entre las variables y la variable etiqueta

PRECISIÓN AL ELIMINAR VARIABLES

Eliminar las columnas con valores más bajos de correlación

Combinación de columnas	
82.7% (0.046)	0, 3, 8, 12
82.1% (0.047)	8, 12, 14
82.3% (0.049)	0, 3, 6, 8, 12, 14
82.0% (0.048)	0, 3, 4, 6, 8, 12, 14

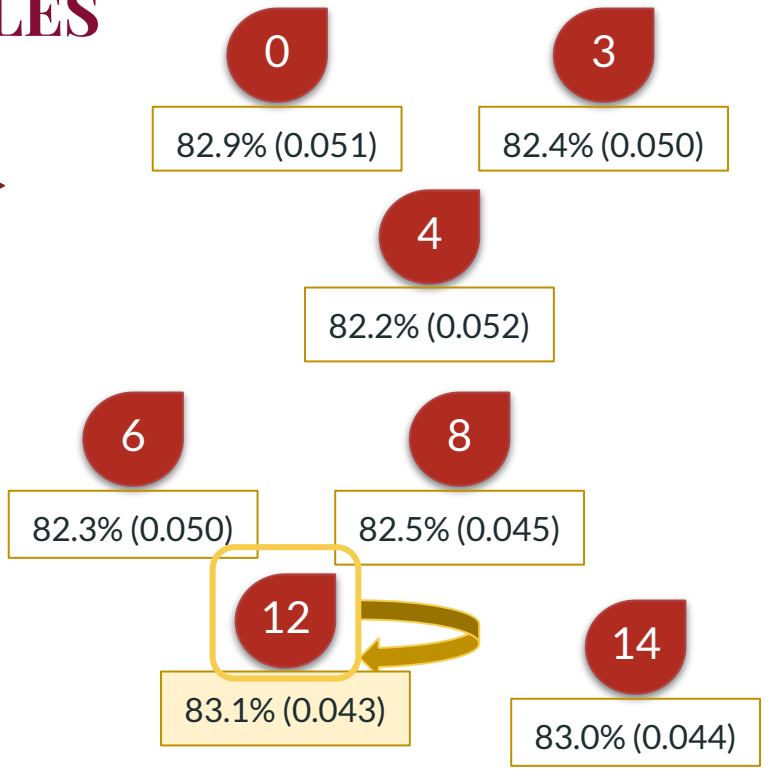

- insured_occupation

Selección de variables

4.2 Numéricas

4.2 Numéricas

4.2.1 ANOVA

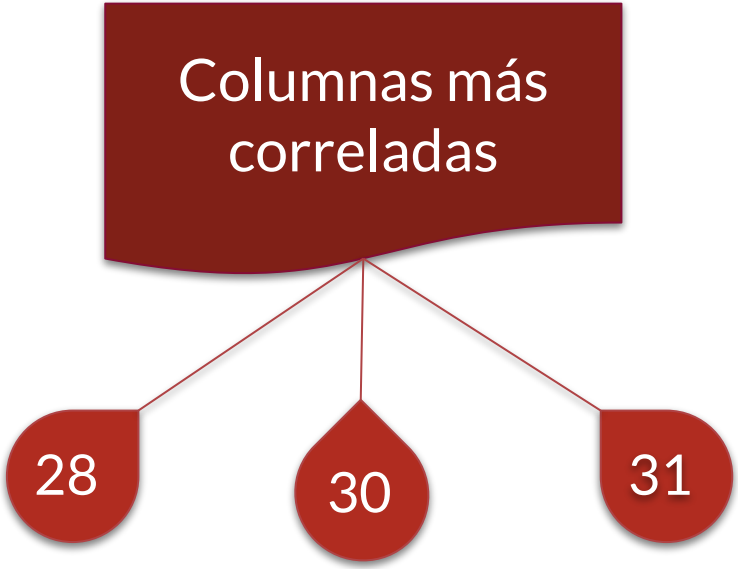

ANOVA

Cuanto mayor sea el coeficiente mayor será la correlación

PRECISIÓN AL ELIMINAR VARIABLES

Eliminar las columnas con valores más bajos de correlación

17

83.2% (0.049)

32

82.3% (0.048)

23

83.2% (0.047)

Combinación de columnas

17, 23	83.0% (0.043)
17, 32	83.2% (0.044)
23, 32	82.8% (0.044)
17, 23, 32	
17,18,20,23,24,32	83.3% (0.046)

83,3% (0.043)

- months_as_customer
- capital_loss
- auto_year

4.2 Numéricas

4.2.2 Información mutua

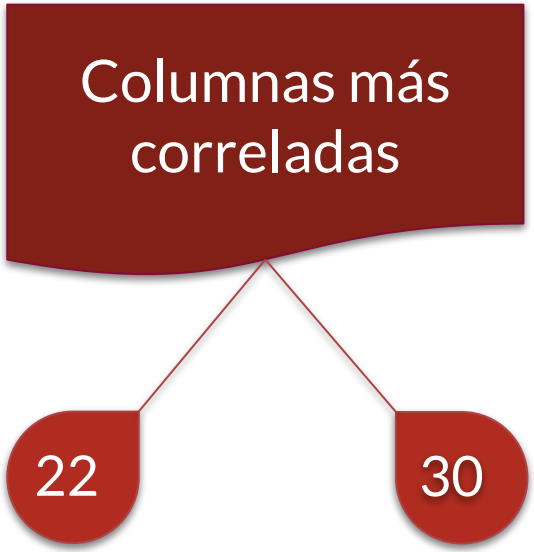

INFORMACIÓN MUTUA

Cuanto mayor sea el coeficiente mayor será la correlación

PRECISIÓN AL ELIMINAR VARIABLES

Eliminar las columnas con valores más bajos de correlación

21

82.6% (0.043)

23

83.2% (0.047)

26

82.9% (0.045)

Combinación de columnas

83.2% (0.049)	21, 23
82.6% (0.048)	21, 26
83.6% (0.049)	23, 26
	21, 23, 26
84.0% (0.055)	21, 23, 26, 27, 28, 32

83.7% (0.048)

- capital_loss
- number_of_vehicles_involved
- total_claim_amount

Importancia de variables

5. Importancia de variables

COLUMNAS MÁS IMPORTANTES

Métodos

- Regresión logística
- Decision tree classifier
- Random forest
- XGB classifier
- Permutación para clasificación

Eliminando las columnas:
1, 4, 7, 12, 19, 22, 23, 25, 27, 28, 32

85.7% ± 0.039%

Modelos

6. Modelos

01	SELECCIÓN DEL MODELO Y LAS VARIABLES MÁS ADECUADAS	• ***XGBoost***: algoritmo de árboles de decisión potenciado por gradientes
02	OPTIMIZACIÓN DE LOS HIPERPARÁMETROS	• Selección de los ***hiperparámetros*** más óptimos para el modelo • Mediante un ***GridSearch*** • ***3 rondas*** distintas de refinamiento

6. Modelos: Selección de hiperparámetros

Parámetros analizados:

- **"max_depth":** profundidad máxima de los nodos de decisión del árbol.
- **"learning_rate"**: rapidez con la que el modelo se ajusta a los errores residuales.
- "**gamma**": pérdida mínima para crear una nueva división.
- **"reg_lambda":** regulación L2 del peso de hoja.
- **"scale_pos_weight"**: relación entre el número de clases negativas y positivas
- **"subsample"**: fracción del conjunto de train que se puede usar para entrenar cada árbol.
- **"colsample_bytree"**: fracción de las características que se puede usar para entrenar cada árbol.

6. Modelos: Resultados

PRECISIÓN:

85 %	**XGBOOST SIN AFINAR**	Con el dataset de train: 81,8 % **Con el dataset de test: 85.5 %**
89 %	**OPTIMIZACIÓN HIPERPARÁMETROS** GridSearch 1a ronda	Con el dataset de train: 84,4 % **Con el dataset de test: 89,0 %**
89 %	**OPTIMIZACIÓN HIPERPARÁMETROS** GridSearch 2a ronda	Con el dataset de train: 84,5 % **Con el dataset de test: 89,0 %**
89 %	**OPTIMIZACIÓN HIPERPARÁMETROS** GridSearch 3a ronda	Con el dataset de train: 84,4 % **Con el dataset de test: 89,0 %**

Deep Learning

7. Deep Learning

Creación de un modelo que use redes neuronales para hacer las predicciones.

USO DE LA LIBRERÍA KERAS

1. INICIALIZACIÓN DE LA RED NEURONAL

2. ADDICIÓN DE CAPAS OCULTAS Y DE SALIDA

3. AJUSTE DEL MODELO AL CONJUNTO DE ENTRENAMIENTO

EVALUACIÓN DEL MODELO:

Precisión: 81,0%

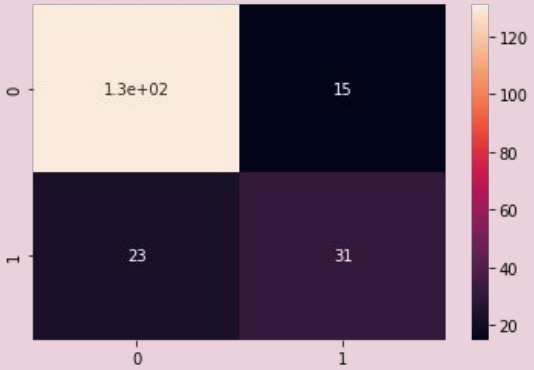

Conclusiones

8. Conclusiones

Limpieza y selección

Con una buena limpieza y selección de los datos se puede mejorar en gran medida la precisión del modelo

Modelo

El modelo que nos da mejores resultados es el **XGBoost**. Importante seleccionar hiperparámetros óptimos.

Deep Learning

No devuelve los resultados más óptimos → Base de datos reducida.

MUCHAS GRACIAS POR VUESTRA ATENCIÓN